

Fouille de données

Analyse d'Articles Scientifiques IA

Ismail OUKHA & Alpha Amadou BALDÉ

2025/2026

Plan

- **Problématique**
 - **Collection des données**
 - **Nettoyage des données**
 - **Analyse et visualisation**
- 

Problématique

Analyser l'évolution des tendances de recherche en Intelligence Artificielle et Machine Learning pour identifier les sujets émergents, les collaborations entre institutions et mesurer l'impact des publications dans ce domaine.

Schéma du pipeline de données (3 phases) :

Collecte → Nettoyage → Analyse et Visualisation



Collection (scrapping)





Selenium



IEE(2018-2025)

```
{
  "title": "",
  "link": "",
  "abstract": "",
  "doi": "",
  "date_publication": "",
  "publisher": "",
  "published_in": "",
  "electronic_issn": "",
  "print_issn": "",
  "authors": [
    {
      "name": "",
      "labs": [
        {
          "lab_name": "",
          "country": ""
        }
      ]
    }
  ],
  "keywords": {
    "ieee_keywords": [],
    "author_keywords": []
  }
}
```

- Intelligence artificielle
- Deep learning
- LLM
- Machine learning
- NLP

Résultat :

Nombre total d'articles : **10077**

Répartition par base d'origine :

- **ieee_ai.db** (3880 articles)
- **ieee_deep_learning.db** (2640 articles)
- **ieee_llm.db** (276 articles)
- **ieee_machine_learning.db** (2630 articles)
- **ieee_nlp.db** (651 articles)

Nettoyage



Suppression de colonnes

- Print ISSN : >85% de valeurs manquantes

Enrichissement géographique

- Extraction automatique des pays depuis les affiliations
- Pattern : "Lab Name, University, Country" → pays

Dédoublonnage

- Articles : suppression de 127 doublons
- Auteurs : normalisation des noms
- Laboratoires et pays : fusion des variantes orthographiques


Résultat : 9982 articles uniques, 36508 auteurs, 159 pays ..



Analyse et visualisation




WordCloud : Top Keywords




Evolution temporelle des keywords


Évolution temporelle des mots-clés dominants




Nombre d'articles par année




Nombre d'auteurs par pays (Top 14)



Évolution annuelle des publications par pays (Top 10)



Articles par thématique



Collaborations




Top 8 des Collaborations Bilatérales en IA/ML (2018-2025)

Rang	Pays 1	Pays 2	Nb Collaborations
1	Chine	États-Unis	1 192
2	Chine	Inde	996
3	Chine	Arabie Saoudite	816
4	Chine	Pakistan	698
5	Chine	Corée du Sud	684
6	Inde	États-Unis	674
7	Arabie Saoudite	États-Unis	544
8	Chine	Malaisie	530

- La Chine domine les collaborations
- Triangle stratégique : Chine - USA - Inde

Collaborations entre pays



Conclusion



Conclusion

Ce projet a permis d'explorer et d'analyser les **tendances de recherche en Intelligence Artificielle et Machine Learning** à partir d'une base de données d'articles scientifiques. Grâce au **clustering KMeans sur les mots-clés**, nous avons identifié **10 thématiques principales**, révélant des sujets émergents comme le deep learning, l'IA appliquée à l'imagerie, la **Vision industrielle** ou le **traitement du langage naturel**.

L'analyse des **réseaux de co-auteurs** a mis en évidence les collaborations entre **chercheurs** et **institutions**, tandis que l'évaluation des publications par nombre de citations a permis de mesurer leur impact scientifique. Les visualisations et le graphe de collaboration offrent une vue claire et structurée du paysage scientifique.

Merci pour votre attention